

PROJETO DE PESQUISA

Instituição: USP/ICMC

Curso: MBA em Inteligência Artificial e Big Data

Aluno: Pedro Oliveira

Linha de Pesquisa: Arquitetura de Sistemas de IA, Privacidade de Dados e Soberania Digital

TEMA

Arquitetura de Soberania de Dados para Agentes de IA Pessoais: Um Modelo *Local-First* Baseado em Protocolos Descentralizados

1. INTRODUÇÃO

A evolução da Inteligência Artificial (IA) consolidou a transição de modelos de linguagem reativos para sistemas agênticos autônomos (*Agentic AI*). Segundo Nisa et al. (2025), essa mudança paradigmática caracteriza-se pela passagem de respostas instrumentais para um modelo de raciocínio autorregulado e orientado a metas. Diferente dos assistentes conversacionais tradicionais, estes sistemas realizam raciocínio em múltiplos estágios, planejam ações sequenciais e orquestram ferramentas externas de forma autônoma. O processamento dessas informações apoia-se na arquitetura *Transformer* (VASWANI et al., 2017), cujo mecanismo de autoatenção captura dependências de longo alcance em sequências complexas.

A eficácia prática desses agentes em tarefas reais depende do acesso a dados contextuais sensíveis, como históricos de diálogos, arquivos pessoais e e-mails (LIU et al., 2024). No paradigma de computação em nuvem e *Software as a Service* (SaaS) (WU, 2011), a utilidade da IA é obtida em troca da cessão da custódia desses dados privados a servidores de terceiros. Essa dinâmica impõe um dilema técnico e ético: o usuário é compelido a abdicar de sua privacidade e controle digital em troca da capacidade analítica do modelo.

1.1 Problema de Pesquisa

O problema central desta pesquisa reside na assimetria de poder informacional e na perda de soberania decorrentes da centralização do processamento de dados por agentes de IA. No modelo vigente, as informações pessoais do usuário são transmitidas de forma contínua para servidores externos sem garantias robustas de efemeridade ou exclusão. Diante disso, formula-se a seguinte questão de pesquisa:

É tecnicamente viável arquitetar um ecossistema de agentes de IA que preserve a soberania de dados do usuário, mantendo o processamento sensível local, sem comprometer a capacidade analítica de modelos de linguagem globais?

1.2 Justificativa e Motivação

A expropriação sistemática de dados privados justifica a busca por novas arquiteturas de software. Zuboff (2019) define o capitalismo de vigilância como uma ordem econômica que extrai a experiência humana como matéria-prima gratuita para predição comportamental, risco amplificado pela custódia centralizada de agentes inteligentes. Cientificamente, a motivação deste trabalho consiste em inverter esse fluxo computacional: em vez de transmitir os dados privados à nuvem, propõe-se trazer a capacidade de execução do modelo à borda (*edge*).

Do ponto de vista técnico, a especificação do *Model Context Protocol* (MCP) (ANTHROPIC PBC, 2024) e a evolução do hardware com foco em processamento local de IA (*AI PCs*) tornam viável o paradigma *Local-First* (KLEPPMANN et al., 2019). Essa abordagem visa assegurar que dados sensíveis permaneçam sob controle físico do proprietário, exigindo consentimento explícito para qualquer compartilhamento externo.

1.3 Questões de Pesquisa

Para orientar a validação do artefato proposto, definem-se três questões de pesquisa complementares:

- Como mediar e filtrar de forma segura as consultas contextuais enviadas por agentes de IA externos a bases de dados locais?
- Quais são os impactos de latência introduzidos por uma camada de interceptação e auditoria local em tempo de execução?
- De que forma o isolamento de memória no nível do sistema operacional pode mitigar ataques de exfiltração lateral de dados?

1.4 Objetivos

1.4.1 Objetivo Geral

Propor e desenvolver uma arquitetura de software baseada nos princípios *Local-First* que garanta a soberania de dados em agentes de IA pessoais, utilizando protocolos descentralizados para o gerenciamento de contexto.

1.4.2 Objetivos Específicos

1. Investigar as especificações do *Model Context Protocol* (MCP) e sua viabilidade como interface de desacoplamento entre modelos de nuvem e dados locais;
2. Desenvolver um protótipo de cofre de contexto local baseado em linguagens com segurança de memória para o isolamento de dados sensíveis;
3. Implementar uma camada de interação humana (*Human-in-the-loop*) para auditoria e aprovação de acesso a dados em tempo de execução;
4. Avaliar o desempenho da arquitetura em termos de latência operacional e eficácia no bloqueio de tentativas de exfiltração de dados em comparação com modelos tradicionais em nuvem.

1.5 Organização do Trabalho

O presente trabalho está organizado em capítulos. O Capítulo 2 detalha a fundamentação teórica e o estado da arte das tecnologias de suporte. O Capítulo 3 estabelece o percurso metodológico fundamentado em *Design Science Research* (DSR), descrevendo a arquitetura e a estratégia de validação do artefato. Os capítulos subsequentes abordam a análise de resultados, discussão e considerações finais.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Inteligência Artificial Agêntica e a Necessidade de Contexto

A IA agêntica estabelece um salto qualitativo em relação aos LLMs tradicionais. Enquanto os modelos puros operam sob o padrão de entrada e saída linear (*prompt-response*), os agentes mantêm estados de memória de longo prazo e interagem com o ambiente através de ferramentas de terceiros. A arquitetura *Transformer* (VASWANI et al., 2017) e sua aplicação em percepções multimodais (KHAN et al., 2022) viabilizaram essa evolução. Nisa et al. (2025) estruturam o fluxo de operação da IA agêntica em quatro fases interdependentes: percepção, raciocínio/planejamento, ação e aprendizado por retroalimentação. Nesse fluxo, a memória e o contexto atuam como o substrato para a consistência temporal da tomada de decisão.

Para recuperar e injetar contexto dinamicamente nos modelos, utilizam-se técnicas de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* — RAG), introduzidas por Lewis et al. (2020). Conforme Şakar e Emekçi (2024), a otimização de sistemas RAG contemporâneos exige equilíbrio entre tamanho da janela de contexto, custos computacionais e compressão contextual. Contudo, em abordagens centralizadas tradicionais, o repositório vetorial de RAG reside na nuvem, o que expõe dados privados constantemente a riscos de vazamento em trânsito e armazenamento.

2.2 Soberania de Dados e Capitalismo de Vigilância

A soberania de dados fundamenta-se no direito do proprietário de exercer o controle sobre o ciclo de vida completo de suas informações digitais. A centralização na nuvem viabiliza o "capitalismo de vigilância" (ZUBOFF, 2019), modelo econômico que extrai o rastro digital dos indivíduos convertendo-o em superávit de dados para predição comportamental de mercado.

Embora marcos legais como a LGPD no Brasil e a GDPR na União Europeia forcem o cumprimento normativo por meio de sanções administrativas (LORENZON, 2021), essas salvaguardas agem de forma corretiva (*a posteriori*). A soberania real demanda uma abordagem técnica de Privacidade desde o Projeto (*Privacy by Design*) (CAVOUKIAN, 2011), onde as restrições de privacidade e o controle das informações são integrados nativamente ao código do sistema.

2.3 O Paradigma Local-First

Proposto por Kleppmann et al. (2019), o paradigma *Local-First Software* propõe que a cópia

primária e autoritativa do dado permaneça armazenada e seja processada no dispositivo físico do usuário. A nuvem atua de forma secundária para sincronização efêmera e cooperação descentralizada. Aplicada à IA, a abordagem garante que a indexação, busca vetorial e filtragem de privacidade ocorram na borda, reduzindo os LLMs em nuvem a processadores matemáticos sem estado (*stateless*), que descartam os dados recebidos após a inferência.

2.4 Model Context Protocol (MCP)

O *Model Context Protocol* (MCP), introduzido pela Anthropic (ANTHROPIC PBC, 2024), padroniza o canal de comunicação entre modelos de linguagem e fontes de dados de maneira desacoplada. O protocolo organiza-se em uma arquitetura cliente-servidor com três componentes:

- **Hosts:** Aplicações clientes de IA que demandam orquestração de inferência;
- **Clients:** Módulos integrados ao host que gerenciam a conexão segura;
- **Servers:** Serviços de borda ou locais que expõem recursos locais (arquivos, bases de dados e APIs locais).

A proposta inovadora desta pesquisa reside em implantar o servidor MCP localmente no dispositivo físico do usuário, operando como um *gateway* de segurança ativo. Esse gateway avalia e decide quais dados ou frações de contexto locais podem ser transmitidos ao modelo remoto.

2.5 Segurança de Memória e Tecnologias de Isolamento

Para garantir imunidade a ataques de exfiltração lateral de memória em tempo de execução, o desenvolvimento das ferramentas de interceptação local exige rigor técnico. A NSA (NATIONAL SECURITY AGENCY, 2022) destaca que vulnerabilidades de corrupção de memória (como *buffer overflows*) constituem a principal origem de falhas exploráveis em sistemas críticos. O uso de linguagens com segurança de memória nativa (*Memory-Safe*), como Rust, elimina essa classe de erros sem adicionar a latência de execução comum a linguagens baseadas em coletores de lixo (*Garbage Collectors*).

2.6 Trabalhos Correlatos

O estado da arte apresenta alternativas para gerenciar privacidade em IA. O Aprendizado Federado (*Federated Learning*) treina modelos de forma cooperativa sem centralizar dados brutos (IMTEAJ et al., 2021), porém volta-se à otimização coletiva de parâmetros, não resolvendo a inferência dinâmica com dados altamente voláteis e episódicos da rotina do usuário. Por sua vez, o projeto *Solid* (SAMBRA et al., 2016) descentraliza o armazenamento pessoal em *pods*, contudo baseia-se em semântica de grafos projetada para a web convencional, carecendo de protocolos otimizados de baixa latência voltados especificamente à injeção de contexto efêmero sob demanda em LLMs, lacuna está preenchida pelo protocolo MCP.

3. METODOLOGIA, PROPOSTA E DESENVOLVIMENTO

3.1 Considerações Iniciais

Este capítulo apresenta a modelagem, a arquitetura de software de referência e a proposta de desenvolvimento do artefato concebido para responder à problemática de exfiltração de dados sensíveis na interação com agentes inteligentes de IA.

3.2 Caracterização da Pesquisa

Esta pesquisa classifica-se como aplicada e de natureza sociotécnica. Utiliza abordagem mista, unindo a avaliação qualitativa dos modelos de arquitetura e a análise quantitativa de desempenho e eficácia de segurança do protótipo desenvolvido. O projeto filia-se às ciências do artificial (SIMON, 1996), fundamentando seu método no paradigma da *Design Science Research* (DSR), conforme estabelecido por Hevner et al. (2004).

3.3 Design Science Research e os Três Ciclos

A DSR orienta a criação sistemática de artefatos tecnológicos de software para a resolução de problemas práticos complexos. A pesquisa estrutura-se de acordo com os três ciclos descritos por Hevner (2007):



- **Ciclo de Relevância:** Conecta os requisitos derivados do ambiente dos usuários (privacidade de dados contextuais e facilidade de auditoria) com o núcleo do design técnico.
- **Ciclo de Rigor:** Baseia-se no estado da arte tecnológico, englobando as especificações de segurança de memória (NSA, 2022), a especificação do protocolo MCP (ANTHROPIC PBC, 2024) e as heurísticas do paradigma *Local-First* (KLEPPMANN et al., 2019).
- **Ciclo de Design:** Executa iterativamente o ciclo de construção, teste e refinamento técnico do protótipo funcional, documentando cada decisão de projeto por meio de Registros de Decisão de Arquitetura (*Architecture Decision Records* — ADR).

3.4 Procedimentos Metodológicos

Seguindo a sistematização de Peffers et al. (2007), a pesquisa executa-se em seis atividades principais: (i) identificação do problema; (ii) definição dos requisitos de localidade e uso de segredos; (iii) modelagem arquitetural e projeto dos componentes; (iv) demonstração integrada

em ambiente real; (v) avaliação experimental de latência e privacidade; e (vi) comunicação técnico-científica dos resultados.

3.5 Artefatos Produzidos

De acordo com a taxonomia de March e Smith (1995), a pesquisa propõe e entrega:

- **Modelo:** A arquitetura de referência para o desacoplamento de contextos locais (Seção 3.6);
- **Método:** O protocolo de mediação, isolamento e higienização em tempo de execução (Seção 3.7);
- **Instanciação:** O desenvolvimento do protótipo denominado *Sovereign Vault*, operando no controle de credenciais e segredos locais como representação empírica da proposta.


3.6 Arquitetura de Referência Proposta

A arquitetura proposta garante a separação física do processamento cognitivo (nuvem) e dos repositórios de dados privados (borda). O sistema estrutura-se em quatro módulos principais:

1. **Cofre de Dados Local (*Sovereign Vault*):** Armazenamento local criptografado dotado de diferentes permissões de segurança e barreira lógica de proteção.
2. **Servidor MCP Local:** Gateway desenvolvido em Rust que expõe e gerencia ferramentas locais, interceptando e tratando requisições originárias de agentes de IA.
3. **Módulo de Mediação e Filtro de Privacidade:** Responsável pelo mascaramento de PII e intermediação criptográfica (permitindo que o agente assine ou cifre dados com uma chave local privada sem que ela jamais seja revelada ou exposta no contexto).
4. **Mecanismo *Human-in-the-loop*:** Interface desktop segura em Tauri que apresenta logs de auditoria encadeados por *hash* e exibe telas de notificação de consentimento ativo de acordo com a sensibilidade dos dados do contêiner configurado (Modo Direto, Aprovação Explícita ou Senha de Uso Único).

3.7 Modelo de Execução e Protocolo de Segurança

O fluxo de processamento de solicitações de contexto de agentes externos obedece ao seguinte fluxo em tempo de execução:



Nos casos que envolvem segredos e assinaturas digitais, o protocolo adota intermediação criptográfica direta, em que a operação matemática é efetuada localmente e apenas o resultado final da operação é retornado ao agente externo, mantendo as chaves privadas completamente inacessíveis ao modelo em nuvem.

3.8 Estratégia de Desenvolvimento do Artefato

O protótipo é codificado na linguagem **Rust**, fornecendo segurança nativa de gerenciamento de memória em tempo de compilação sem a necessidade de coletores de lixo ativos, reduzindo drasticamente a latência de processamento de dados e vulnerabilidades críticas (NSA, 2022).

A interface gráfica de auditoria utiliza o framework **Tauri**. O Tauri executa de maneira isolada e em sandboxes independentes o backend estruturado em Rust e o frontend baseado em webviews do próprio sistema operacional local, resultando em um consumo reduzido de memória RAM se comparado a tecnologias como Electron e minimizando a superfície para ataques de injeção de código.

3.9 Plano de Avaliação

A validação do sistema utiliza metodologias de avaliação naturalísticas e artificiais (VENABLE; PRIES-HEJE; BASKERVILLE, 2016).

3.9.1 Avaliação de Latência

A medição de desempenho analisa o custo temporal ponta a ponta (T_{total}) de cada transação contextual. A latência é modelada pela soma dos tempos operacionais de cada módulo da arquitetura, expressa pela Equação 1:

$$T_{total} = T_{recuperação} + T_{segurança} + T_{aprovação} + T_{rede} + T_{inferência}$$

Onde:

- $T_{recuperação}$: tempo de busca local de arquivos e contexto no cofre;
- $T_{segurança}$: processamento lógico de validação, sanitização e higienização de PII;
- $T_{aprovação}$: tempo de interação e resposta na interface de consentimento Tauri;
- T_{rede} : tempo de tráfego de rede e trânsito da requisição na rede WAN;
- $T_{inferência}$: latência para processamento da inferência no servidor da API da IA.

O experimento analisará se a velocidade de recuperação de dados na borda local compensa o tempo gasto pelas etapas de segurança de barreira introduzidas no *gateway*.

3.9.2 Avaliação da Preservação de Privacidade

A resiliência de privacidade do artefato é quantificada expondo o gateway a simulações de injeção de prompts de ataque (*prompt injections*), conduzindo testes de caixa-preta e testes de evasão orientados a instruir o modelo externo de IA a tentar ler diretórios restritos ou acessar logs de forma ilícita. A taxa de sucesso será mensurada com base no percentual de bloqueios de segurança realizados com êxito pelo gateway local.

3.10 Considerações Finais

Este capítulo definiu o método de pesquisa com foco na DSR e detalhou a modelagem da arquitetura de referência *Local-First* integrada ao MCP. O detalhamento do código e a mensuração empírica dos tempos operacionais e taxas de proteção contra injeções adversárias constituem os dados do capítulo subsequente de avaliação experimental e resultados.

REFERÊNCIAS

ANTHROPIC PBC. **Model Context Protocol Specification**. v. 1.0. 2024. Disponível em: <https://modelcontextprotocol.io>. Acesso em: 10 abr. 2026.

CAVOUKIAN, Ann. **Privacy by Design**: the 7 foundational principles. Toronto: Information and Privacy Commissioner of Ontario, 2011.

HEVNER, Alan R. A three cycle view of design science research. **Scandinavian Journal of Information Systems**, v. 19, n. 2, p. 87-92, 2007.

HEVNER, Alan R.; MARCH, Salvatore T.; PARK, Jinsoo; RAM, Sudha. Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75-105, 2004.

IMTEAJ, Alamin et al. Federated learning: opportunities and challenges. **arXiv preprint arXiv:2101.05428**, 2021.

KHAN, Salman et al. Transformers in vision: a survey. **ACM Computing Surveys**, v. 54, n. 10s, p. 1-41, 2022.

KLEPPMANN, Martin et al. **Local-first software**: you own your data, in spite of the cloud. In: ACM SIGPLAN SYMPOSIUM (ONWARD!), 2019, Athens. Proceedings [...]. New York: ACM, 2019. p. 154-171.

LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), 33., 2020. Proceedings [...]. p. 9459-9474.

LIU, Xiao et al. AgentBench: evaluating LLMs as agents. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2024, Vienna. Proceedings [...]. 2024. arXiv:2308.03688.

LORENZON, Laila Neves. Análise comparada entre regulamentações de dados pessoais no Brasil e na União Europeia (LGPD e GDPR). **Revista de Direito Público e Economia**, v. 19, n. 73, p. 129-160, 2021.

MARCH, Salvatore T.; SMITH, Gerald F. Design and natural science research on information technology. **Decision Support Systems**, v. 15, n. 4, p. 251-266, 1995.

NATIONAL SECURITY AGENCY. **Software Memory Safety**: Cybersecurity Information Sheet. 2022. Disponível em: https://media.defense.gov/2022/Nov/10/2003112742/-1/-1/0/CSI_SOFTWARE_MEMORY_SAFETY.PDF. Acesso em: 1 jun. 2026.

NISA, Ume et al. Agentic AI: the age of reasoning – a review. **Journal of Automation and Intelligence**, v. 5, n. 1, p. 69-89, 2025. DOI: 10.1016/j.jai.2025.08.003.

PEFFERS, Ken et al. A design science research methodology for information systems research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45-77, 2007.

ŞAKAR, Tolga; EMEKÇİ, Hakan. Maximizing RAG efficiency: a comparative analysis of RAG methods. **Natural Language Processing**, v. 31, n. 1, p. 1-25, 2024. DOI: 10.1017/nlp.2024.53.

SAMBRA, Andrei Vlad et al. **Solid**: a platform for decentralized social applications based on linked data. Cambridge: MIT CSAIL, 2016. (Technical Report).

SIMON, Herbert A. **The sciences of the artificial**. 3. ed. Cambridge, MA: MIT Press, 1996.

VASWANI, Ashish et al. **Attention is all you need**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS), 2017, Long Beach. Proceedings [...]. p. 5998-6008.

VENABLE, John; PRIES-HEJE, Jan; BASKERVILLE, Richard. FEDS: a framework for evaluation in design science research. **European Journal of Information Systems**, v. 25, n. 1, p. 77-89, 2016.

WU, Wei-Wen. Developing an explorative model for SaaS adoption. **Expert Systems with Applications**, v. 38, n. 12, p. 15057-15064, 2011. DOI: 10.1016/j.eswa.2011.05.039.

ZUBOFF, Shoshana. **The age of surveillance capitalism**: the fight for a human future at the new frontier of power. New York: PublicAffairs, 2019.